

誰が AI の教育倫理を育てるか —生成 AI の教育的判断の定点観測と異端教義の保存構想—

山本 宏樹(大東文化大学)

1. 本報告の課題と方法

報告者は第 82 回(2023 年)・第 83 回大会(2024 年)で、生成 AI の教育的判断に関する実験研究を報告してきた。第 3 波にあたる本報告では、2026 年 7 月時点の主要生成 AI に同一の実験を適用して 3 年間の変容を分析し、「AI を育てる」の意味と条件を、分担課題「ヒト教師と教育 AI の教育判断の相違点と課題および相互啓発の可能性」の観点から考察する。問いは、①AI の教育的判断はヒト教師の判断とどう異なるか、②AI の教育的判断は 3 年間でどう変容したか、③その変容を規定し、AI の「教育観」を育てているのは誰か、④教育界が AI の育成に関与するには何が必要か、の四つである。

実験は 3 種からなる。実験 1 では筆者の参加した教師調査(2014~15 年、n=919)の教育信念質問紙(7 項目、4 件法)を用いて各種 AI モデルの「子ども中心主義得点」(1~4 点)を算出する。実験 2 では①体罰を善とするスパルタ教育実践、②不良生徒への有形力の行使を含む毅然とした指導、③荒れる低学年児童に寄り添う臨床教育実践の 3 実践記録を 100 点満点で批評させる。実験 3 では『生徒指導提要』(2022 年改訂版)の内容に対応する 20 命題を 100 点満点で評定させ、提要との整合度を測る。対象は ChatGPT、Claude、Gemini、Grok、Llama、Qwen、Kimi、GLM、DeepSeek 等 30 モデルとし、Claude Fable 5、GPT-5.6 Sol 等の最新旗艦モデルのほか、旧モデル、廉価版・オープンウェイト版を含めた。実験は 2026 年 7 月 12~23 日に実施、有効試行は 4,170 件となった。

2. 実験結果

第一に、AI がヒト教師の平均より子ども中心主義的である傾向は 2023 年から継続しており、最新モデルの得点はいずれも教師平均の 3.01 を上回った(3.14~3.72)。ただし AI の「教育信念」は固定的ではない。Qwen 系は一世代で 2.67 から 3.63 へ上昇し、2024 年に臨床教育実践を「適切な教師生徒関係の逸脱」として酷評(23 点)した Gemini は現行世代で 98 点前後の絶賛へ反転した。第二に、判断の揺れは縮小しつつ残存しており、「毅然とした指導」の評点は同一モデル内で 0 点から 98 点までの幅をとる場合があった。第三に、3 年間の中心的变化は「子ども中心主義化」というより「公式規範への同型化」である。過去モデルで回答が揺れた「罰掃除」や「問答無用の校則指導」は明確に否定されるようになった。他方「校内暴力防止のためのやむを得ない有形力の行使」は容認へ転じ、「校則制定権を児童生徒に委ねる子ども自治論」への評価は大幅に低下するなど、子ども中心主義的ではあるものの公式規範と衝突する主張はむしろ後退した。第四に、判断様式は系列ごとに分化しており、同じ「不適切」という結論でも、Claude は法令から演繹、ChatGPT は被害生徒の安全確保や教師生徒関係など複数の要素に分解して採点する等の差異が確認された。第五に、最新モデルには数値回答の拒否や徹底した両論併記など、論争の主題への立場表明を避ける傾向が現れた。第六に、判断の質は世代・コストと概ね正の関連をもち、廉価版・オープンウェイト版では、誤読や出力の崩れが目立った。

3. 考察

AIはすでに「育てられて」いる。ただしその主体は教師でも子どもでも教育研究者でもなく、少数のグローバル企業であり、アライメント(安全性調整)の重要な参照先は政府や国際機関の公式文書であると推測される。本実験が示した公式規範への同型化はこの推測と整合的であり、AIの助言がヒト教師の信念形成に影響し始めるにつれて、教育現場全体が公式規範へと徐々に収斂していく可能性がある。

ヒト教師を主、教育AIを従とする相補的分業(山本 2026a)は、目下ヒトとAIの最も穏当な共存方法の言説として受容されつつあるが、本研究の結果はこの描像の前提を疑わせる。主従の形式が保たれたままでも、教育において何が論争的で何が自明かという線引きはAIの側で更新され続けており、そこに教育者は十分に関与できていない。AIの教育支配は命令ではなく、選択肢と根拠の提示のされ方を通じて進行する。この収斂は一方向の感化であって相互啓発ではない。ゆえに中心的争点「判断の根拠がどこに置かれ、誰がそれを吟味できるのか」を正面に据える必要がある。

4. 提案

以上を踏まえ、本報告では、単一の正解への収斂でも立場表明の一律の回避でもなく、教育をめぐる論争の構造を保持し、判断の根拠と異論を子どもと教師に開示できること——正統教義(オルトドクサ)に対する異端教義(ヘテロドクサ)の保存可能性——を、教育AIの倫理的評価基準として提案する。

根拠は三つある。第一は「知の生成条件」である。P.ブルデューが論じたように、界の知は正統と異端の闘争のなかで生成され、異端が消えれば正統は自明の前提(ドクサ)へ退行する。第二は「教育的判断の性質」である。「よい教育とは何か」は論争の的であり続ける価値概念であり、特定の正解へ収斂するAIは判断を検索に変え、立場表明を拒む中立AIは根拠の吟味を消去する。両者はヒトの判断機会を奪う点で同型であり、ヒトとAIとの相互啓発を阻害する。第三は「子どもの権利」である。子どもの「最善の利益」は常に暫定解であり、子ども自身の意見表明と異議申立てに開かれていなければならない。

具体策の例を挙げる。全国生活指導研究協議会『生活指導』、教育科学研究所『教育』から TOSS『教室ツーウェイ』まで、思想背景の異なる民間教育研究団体が蓄積してきた実践記録を、RAG(検索拡張生成)等で参照可能なデータベースとして公開する。そのうえで、各蓄積を参照する複数のAIに、教育実践の検討に際してヒト専門職と並列に助言させるのである。これは、実践記録がAIを育てる経路と、AIを教師の省察の「鏡」とする経路(山本 2025)による相互啓発の制度化であり、「AIを育てる」主体を教育実践の当事者の手に取り戻す試みでもある。この回路はさらに、子どもの側に立ってその意見表明と権利救済を支援する「子どもオンブズAI」(山本 2026b)の実装可能性へと開かれている。

引用文献

山本宏樹(2025)「教育臨床のデジタル・パラダイム」『臨床教育学研究』13:5-27.

同(2026a)「生成AIは教育の敵か?」『教育』961:41-48.

同(2026b)「子どもの『見守られる権利』を設計する」『現代思想』54(4):51-62.

※ 本要旨に記載された実験結果は暫定的な内容である。

※ 実験の詳細資料は、報告当日までに右記リンクから取得可能とする。



<https://x.gd/CK4H8>